

Данный текст является русскоязычной версией опубликованной на английском языке статьи и представлен в авторской редакции только на данном сайте!

UDC 004.896

Doi: 10.31772/2587-6066-2020-21-2-206-214

For citation: Tynchenko V. S., Golovenok I. A., Petrenko V. E., Milov A. V., Murygin A. V. Gradient boosting method application to support process decisions in the electron-beam welding proces. *Siberian Journal of Science and Technology*. 2020, Vol. 21, No. 2, P. 206–214. Doi: 10.31772/2587-6066-2020-21-2-206-214.

Для цитирования: Применение метода градиентного бустинга для поддержки принятия технологических решений в процессе электронно-лучевой сварки / В. С. Тынченко, И. А. Головенко, В. Е. Петренко и др. // Сибирский журнал науки и технологий. 2020. Т. 21, № 2. С. 206–214. Doi: 10.31772/2587-6066-2020-21-2-206-214.

ПРИМЕНЕНИЕ МЕТОДА ГРАДИЕНТНОГО БУСТИНГА ДЛЯ ПОДДЕРЖКИ ПРИНЯТИЯ ТЕХНОЛОГИЧЕСКИХ РЕШЕНИЙ В ПРОЦЕССЕ ЭЛЕКТРОННО-ЛУЧЕВОЙ СВАРКИ

В. С. Тынченко, И. А. Головенко, В. Е. Петренко, А. В. Милов, А. В. Мурыгин

Сибирский государственный университет науки и технологий имени академика М. Ф. Решетнева
Российская Федерация, 660037, г. Красноярск, просп. им. газ. «Красноярский рабочий», 31
E-mail: vadimond@mail.ru

Целью исследования является создание математической модели технологического процесса изготовления неразъемных соединений разнородных материалов на основе электронно-лучевой сварки с использованием алгоритмов машинного обучения. Каждый из соединяемых элементов представляет собой ответственный узел комплексного устройства, в связи с чем выставляются жесткие критерии к качеству сварного соединения. В сущности, поставленная задача представляет собой задачу регрессии. Существует множество алгоритмов, подходящих для решения задачи регрессии. Однако зачастую использование одного алгоритма не обеспечивает достаточной точности полученного результата. Одним из способов решения такой проблемы является построение композиции алгоритмов для компенсации проблем каждого из них. Одним из наиболее эффективных и мощных алгоритмов композиции является градиентный бустинг. Использование данного алгоритма повысит качество модели регрессии. Предлагаемая модель позволит технологу задавать параметры технологического процесса и получать оценку качества конечного изделия равно как по заданию входных, так и выходных величин. Использование методов оценки и прогнозирования снизит временные и трудовые затраты на поиск, отработку и наладку технологического процесса. Приводится описание алгоритма градиентного бустинга, а также анализ применимости данного алгоритма к модели, равно как и заключение касательно областей его применимости и достоверности прогнозов, получаемых при его использовании. Кроме того, рассматривается процесс непосредственного обучения модели на основе данных, полученных в рамках проведения поисковых экспериментов для улучшения качества конечного изделия. Результаты анализа применимости позволяют судить о допустимости использования предложенного метода для процессов, имеющих схожие статистические зависимости. Применение предложенного подхода позволит осуществить поддержку принятия технологических решений

специалистов по электронно-лучевой сварке при отработке технологического процесса и при вводе в производство новых видов продукции.

Ключевые слова: электронно-лучевая сварка, технологический процесс, эксперименты, градиентный бустинг, машинное обучение.

GRADIENT BOOSTING METHOD APPLICATION TO SUPPORT PROCESS DECISIONS IN THE ELECTRON-BEAM WELDING PROCESS

V. S. Tynchenko, I. A. Golovenok, V. E. Petrenko, A. V. Milov, A. V. Murygin

Reshetnev Siberian State University of Science and Technology
31, Krasnoyarskii rabochii prospekt, Krasnoyarsk, 660037, Russian Federation
E-mail: vadimond@mail.ru

The purpose of the study is to develop a technological process mathematical model of creating permanent joints of dissimilar materials based on electron-beam welding using machine learning algorithms. Each of the connected elements is a responsible unit of the complex device, due to this fact, strict criteria are set for the quality of the welded joint. In essence, the set task is a regression task. There are many algorithms suitable for solving the regression problem. However, often the use of one algorithm does not provide sufficient accuracy of the result. One way to solve this problem is to develop a composition of algorithms to compensate for the problems of each of them. One of the most effective and potent compositional algorithms is the gradient boosting algorithm. This algorithm use will improve the quality of the regression model. The proposed model will allow the technologist to set the process parameters and to get an assessment of the final product quality, as well as by setting input and output values. The use of assessment methods and forecasting will reduce the time and labor costs of searching, developing and adjusting the process. A description of the gradient boosting algorithm is given, as well as an analysis of the applicability of this algorithm to the model and a conclusion regarding the areas of its applicability and the reliability of the forecasts obtained by its direct use. In addition, we consider the process of direct model training based on the data obtained as part of search experiments to improve the quality of final product. The results of the applicability analysis allow us to judge the admissibility of using the proposed method for processes that have similar statistical dependencies. The application of the proposed approach will make it possible to support the adoption of technological decisions by specialists in electron-beam welding during the development of the technological process and when new types of products are put into production.

Keywords: electron-beam welding, technological process, experiments, gradient boosting, machine learning.

Введение. Для ряда технологических процессов остро стоит вопрос подбора или осознанного выбора оптимальных параметров, которые зависят от предъявляемых критериев качества к конечному изделию [1–5]. Более того, данное утверждение справедливо и для способов поиска улучшения или преобразования уже налаженного технологического процесса. Например, в ситуации, когда необходимо улучшить один из параметров, определяющих качество конечного изделия, не изменяя остальные или не допуская их отклонение на определённую величину. Однако часть процессов, таких как электронно-лучевая сварка [6; 7], относительно сложно поддаются наладке или же изменению, в связи с недостаточной изученностью либо с комплексной сложностью, когда невозможно учесть все факторы в том виде, который бы позволил однозначно определять потенциальные изменения

и влияние параметров на процесс в целом. Это влечет необходимость поиска методов упрощения процессов наладки и преобразования технологических процессов.

Рассматривая технологический процесс как замкнутую систему с различными входными и выходными параметрами, можно построить соответствующую модель и в дальнейшем использовать ее в качестве инструмента для прогноза и оптимизацию. Целью данной работы явилось исследование одного из алгоритмов машинного обучения как предмета создания комплексной математической модели, которая позволила бы сформировать осознанный взгляд на выбор параметров технологического процесса как в локальном, так и в глобальном поиске оптимума, определяемого технологом. Такой подход в существенной мере позволит снизить время на наладку технологического процесса, а также стоимость поисковых исследований, что в конечном счете положительным образом отразится на стоимости и качестве выпускаемых изделий.

В сущности, поставленная задача представляет собой задачу регрессии. Одним из наиболее эффективных и мощных алгоритмов композиции является алгоритм градиентного бустинга [8–13]. Использование предложенной математической модели позволит повысить качество управления технологическим процессом электронно-лучевой сварки за счет реализации поддержки принятия технологических решений с использованием алгоритма градиентного бустинга. В перспективе данный подход можно использовать для технологических процессов, имеющих схожие статистические зависимости.

Описание набора обучающих данных. В качестве исходных данных были взяты результаты экспериментальных исследований, проводимых в целях улучшения технологического процесса электронно-лучевой сварки изделия, сборка которого складывается из элементов, состоящих из разнородного материала. Установка электронно-лучевой сварки, на которой проводились исследования, предназначена для сварки электронным лучом в глубоком вакууме деталей сборочных единиц из нержавеющей сталей, титановых, алюминиевых и специальных сплавов. Существующая установка электронно-лучевой сварки обеспечивает повторяемость режимов в рамках возможностей реализованной системы управления. Работы по сварке выполнялись на образцах-имитаторах, соответствующих технологическому изделию. Для уменьшения вложения энергии при сварке:

- 1) снижалась величина сварочного тока (IW);
- 2) увеличивался ток фокусировки электронного пучка (IF);
- 3) увеличивалась скорость сварки (VW);
- 4) менялось расстояние от поверхности образцов до электронно-оптической системы (FP).

По совокупности параметров технологических режимов обеспечивались минимально возможные размеры сварных швов: глубина шва (Depth) и ширина шва (Width).

В процессе выполнения работ была произведена электронно-лучевая сварка 18-ти единиц образцов. Результаты металлографического контроля по размерам сварочного шва для каждого образца проводились в 4-х поперечных сечениях сварочного шва. Ускоряющее напряжение было постоянным в диапазоне 19,8–20 кВ. Набор полученных данных собран в составе режимов сварки, размеров сварочных швов в поперечных сечениях всех образцов. Статистические показатели набора обучающих данных указаны в табл. 1.

Таблица 1

Статистические показатели набора обучающих данных

Показатель	IW	IF	VW	FP	Depth	Width
Количество	72	72	72	72	72	72
Среднее выборочное	45,666	141,333	8,639	78,333	1,196	1,970
Среднее квадратичное отклонение	1,678	5,146	2,061	21,494	0,225	0,279

Минимум	43	131	4,5	50	0,80	1,68
25 %	44	139	8	60	1,08	1,76
50 %	45	141	9	80	1,20	1,84
75 %	47	146	10	80	1,29	2,05
Максимум	49	150	12	125	1,76	2,60

Математическая постановка задачи. Формальная постановка задачи поддержки принятия технологических решений в процессе электронно-лучевой сварки представляет собой задачу регрессии, в которой по набору исходных параметров технологического процесса необходимо спрогнозировать характеристики сварного соединения. Математическая постановка задачи управления в данном случае будет выглядеть следующим образом. Пусть имеются набор параметров технологического процесса: IW – величина сварочного тока; IF – ток фокусировки электронного луча; VW – скорость сварки; FP – расстояние от поверхности образцов до электронно-оптической системы; $Depth$ – глубина сварного шва; $Width$ – ширина сварного шва. Существует неизвестная целевая зависимость отображения: $y^*: (IW, IF, VW, FP) \rightarrow (Depth, Width)$, значение которой известно только на обучающей выборке. Необходимо разработать алгоритм отображения.

В рамках данной работы имеем:

1. Набор данных: $L = \{x_i, y_i\}, i = 1..n$, где:

- x_{iw} – ток сварки, мА;
- x_{if} – ток фокусировки, мА;
- x_{vw} – скорость сварки, об/мин;
- x_{fp} – расстояние до ЭОСС, мм;
- y_{depth} – глубина сварочного шва;
- y_{width} – ширина сварочного шва;
- x принадлежит Q^4 , y принадлежит Q^2 , где Q – множество положительных рациональных чисел.

2. Модель $f(X)$, которая предсказывает значения для каждого объекта, где X – параметры технологического процесса, в данном случае технологические параметры электронно-лучевой сварки. Для оценки качества модели $f(X)$ в рамках данной работы используются следующие метрики: средняя квадратическая ошибка (MSE); средняя абсолютная ошибка (MAE); коэффициент детерминации R^2 (R^2).

В рамках данного исследования $f(x)$ – ансамбль моделей «Градиентный бустинг» (Gradient Boosting Regressor).

Градиентный бустинг. Модель Gradient Boosting Regressor была реализована с помощью пакета scikit-learn 0.22.2 на Python 3.8 [14; 15]. Бустинг – это техника построения ансамблей, в которой предсказатели построены не независимо, а последовательно. Это техника использует идею о том, что следующая модель будет учиться на ошибках предыдущей. Они имеют неравную вероятность появления в последующих моделях, и чаще появятся те, что дают наибольшую ошибку [16]. Алгоритм Градиентного бустинга:

1. Инициализировать модель константным значением:

$$\hat{f}(x) = \hat{f}_0, \hat{f}_0 = y, y \in \mathbb{R}:$$

$$\hat{f}_0 = \arg \min_y \sum_{i=1}^n L(y_i, y).$$

2. Для каждой итерации $t = 1..M$ ($M = n_estimators$) повторять:

а) посчитать псевдо-остатки r_t .

$$r_{it} = - \left[\frac{\partial L(y_i, f(x_i))}{\partial f(x_i)} \right]_{f(x)=\hat{f}(x)}, i = 1, \dots, n;$$

б) построить новый базовый алгоритм $h_t(x)$ как регрессию на псевдо-остатках

$$\{(x_i, r_{it})\}_{i=1..n};$$

в) найти оптимальный коэффициент ρ_t при $h_t(x)$ относительно исходной функции потерь

$$\rho_t = \arg \min_{\rho} \sum_{i=1}^n L(y_i, \hat{f}(x_i) + \rho \cdot h_t(x_i, \theta));$$

г) записать модель

$$\hat{f}_t(x) = \rho_t \cdot h_t(x);$$

д) обновить текущее приближение

$$\hat{f}(x) \leftarrow \hat{f}(x) + \hat{f}_t(x) = \sum_{i=0}^t \hat{f}_i(x).$$

3. Скомпоновать итоговую модель

$$f(x) = \sum_{i=0}^M \hat{f}_i(x).$$

В рамках данной работы реализован градиентный бустинг над решающими деревьями. Данная реализация градиентного бустинга позволяет построить модель в форме ансамбля слабых предсказывающих моделей деревьев решений.

В scikit-learn модель GradientBoostingRegressor строит модель поэтапно, что позволяет оптимизировать произвольные дифференцируемые функции потерь. На каждом этапе дерево решений соответствует отрицательному градиенту заданной функции потерь. Основные параметры в GradientBoostingRegressor, которые подбирались для поиска оптимального решения:

1. n_estimators – количество этапов повышения градиента (количество используемых слабых деревьев решений);
2. loss – функция потерь для оптимизации (MSE, MAE);
3. max_depth – максимальная глубина каждого дерева решений;
4. max_features – число признаков, по которым ищется разбиение;
5. min_samples_split – минимальное количество объектов, необходимое для разделения внутреннего узла дерева;
6. min_samples_leaf – минимальное число объектов в листе.

Подбор оптимальных параметров для модели. Для подбора оптимальных параметров в модели применялась функция GridSearchCV, входящая в состав модуля scikit-learn. Функция GridSearchCV реализует исчерпывающий поиск по указанным значениям параметров для модели. Данная функция реализует методы «подбора» и «оценки».

Параметры модели, оптимизируются путем перекрестной проверки (cross-validation) по сетке параметров.

Главные параметры функции GridSearchCV:

1. estimator – модель, в которой проходит подбор;
2. param_grid – наборы гипер-параметров, которые необходимо проверить;
3. scoring – метрика, по которой будет происходить оценивание.
4. cv – количество блоков в перекрестной проверке.

Экспериментальные исследования.

Постановка эксперимента. Настройка и обучение модели проводились отдельно для каждого: y_{depth} и y_{width} , на множестве параметров X . Обучение модели с оптимальными параметрами на полном наборе данных (dataset) обозначено как $train_score$. Для проверки точности предсказания модели (cv_score) использовалась перекрестная оценка (cross-validation). Для получения оценки путем перекрестной проверки используется функция $cross_val_score$ из модуля `scikit-learn`.

Количество блоков в перекрестной проверке равно 4-м. Для повышения точности проверки выполняется алгоритм:

Для каждого $i = 1, \dots, K$:

- 1) случайным образом перетасовываем $dataset - DS_i$;
- 2) получаем оценку с помощью $cross_val_score$ на $DS_i - S_i$;
- 3) итоговая оценка является средним значением

$$cv_score_K = \frac{1}{K} \sum_{i=1}^K S_i .$$

Количество K выбирается таким образом, пока

$$cv_score_K - cv_score_{K-1} \leq 0.1 .$$

Подбор параметров для модели Gradient Boosting Regressor (GBR).

Модель для глубины шва. Гипер-параметры модели выбирались среди следующих значений:

1. $n_estimators$: 10, 20, 30, 40, 50, 60, 70, 80, 90, 100;
2. $loss$: MSE, MAE;
3. max_depth : 1, 2, 3, 4;
4. $max_features$: 1, 2, 3, 4;
5. $min_samples_leaf$: 1, 2, 3, 4;
6. $min_samples_split$: 2, 3, 4, 5.

Проводился поиск оптимальных гипер-параметров, с использованием *GridSearchCV*, где в качестве метрики использовалась средняя абсолютная ошибка (MAE), по которой происходит оценивание каждого теста, а количество блоков в перекрестной проверке равно 5.

Лучшие десять результатов в порядке убывания отображены в табл. 2.

Таблица 2

Лучшие результаты подбора параметров модели для глубины шва

$n_estimators$	$loss$	max_depth	$max_features$	$min_samples_leaf$	$min_samples_split$	$mean_test_score$
100	MSE	3	2	1	5	0,050862
90	MSE	3	2	1	5	0,050887
80	MSE	3	3	1	5	0,050893
80	MSE	3	2	1	5	0,050893
80	MSE	3	4	1	4	0,050893
100	MSE	3	3	1	5	0,050896
90	MSE	3	3	1	2	0,050898
80	MSE	3	4	1	2	0,050899
80	MSE	3	4	1	3	0,050899
100	MSE	3	3	1	2	0,050900

В табл. 2 использованы следующие обозначения: mean_test_score – среднее значение оценки на test.

При фиксации значений (loss = MSE, max_depth = 3, max_features = 2, min_samples_leaf = 1, min_samples_split = 5) были построены графики изменения n_estimators (рис. 1).




Рис. 1. Изменения параметра n_estimators
Fig. 1. The changes of n_estimators parameter

При фиксации значений (n_estimators = 100, loss = MSE, max_features = 2, min_samples_leaf = 1, min_samples_split = 5) были построены графики изменения max_depth (рис. 2).




Рис. 2. Изменения параметра max_depth.
Fig. 2. The changes of max_depth parameter.

При фиксации значений (n_estimators = 100, loss = MSE, max_depth = 3, max_features = 2, min_samples_leaf = 1) были построены графики изменения min_samples_split (рис. 3).




Рис. 3. Изменения параметра min_samples_split.
Fig. 3. The changes of min_samples_split parameter.

Как видно из рис. 3, лучшую оценку на тесте получило значение min_samples_split = 7.

Наилучшие гиперпараметры: n_estimators = 100; loss = MSE; max_depth = 3; max_features = 2; min_samples_leaf = 1; min_samples_split = 7. Важность технических параметров распределилась следующим образом: x_{iw} – 6 %; x_{if} – 26 %; x_{vw} – 44 %; x_{fp} – 24 %. В табл. 3 представлены оценки математической модели по глубине сварного шва.

Таблица 3

Оценки математической модели для глубины сварного шва

Оценки	R2	MAE
train_score	0,932651	0,042958
cv_score	0,896255	0,044262

Проводился поиск оптимальных гиперпараметров с использованием *GridSearchCV*, где метрика – MAE, по которой происходит оценивание каждого теста, а количество блоков в перекрестной проверке – 5. Лучшие десять результатов, в порядке убывания, отображены в табл. 4.

Таблица 4

Лучшие результаты подбора параметров модели для ширины шва

n_estimators	loss	max depth	max features	min samples leaf	min samples split	mean_test_score
100	MAE	3	3	1	4	0,030108
80	MAE	3	3	1	4	0,030112
90	MAE	3	3	1	4	0,030166
70	MAE	3	3	1	4	0,030391
100	MAE	3	3	1	5	0,030459
80	MAE	3	3	1	5	0,030475
90	MAE	3	3	1	5	0,030509
80	MAE	3	3	1	3	0,030615
80	MAE	3	3	1	2	0,030615
60	MAE	3	3	1	4	0,030649

В табл. 4 использованы следующие обозначения: mean_test_score – среднее значение оценки на test.

При фиксации значений (loss = MSE, max_depth = 3, max_features = 3, min_samples_leaf = 1, min_samples_split = 4) были построены графики изменения n_estimators (рис. 4).




Рис. 4. Изменения параметра n_estimators
Fig. 4. The changes of n_estimators parameter

При фиксации значений (n_estimators = 100, loss = MAE, max_features = 3, min_samples_leaf = 1, min_samples_split = 4) были построены графики изменения max_depth (рис. 5).




Рис. 5. Изменения параметра max_depth
Fig. 5. The changes of max_depth parameter

При фиксации значений (n_estimators = 100, loss = MAE, max_depth = 3, max_features = 3, min_samples_leaf = 1) были построены графики изменения min_samples_split (рис. 6).




Рис. 6. Изменения параметра min_samples_split
Fig. 6. The changes of min_samples_split parameter

Наилучшие гиперпараметры: $n_estimators = 100$, $loss = MAE$, $max_depth = 3$, $max_features = 3$, $min_samples_leaf = 1$, $min_samples_split = 4$.

Важность технических параметров распределилось следующим образом: $x_{iw} - 13\%$; $x_{if} - 41\%$; $x_{vw} - 33\%$; $x_{fp} - 13\%$.

В табл. 5 приведены результаты оценок.

Таблица 5

Оценки модели по ширине сварного шва

Оценки	R2	MAE
train_score	0,970136	0,030648
cv_score	0,960603	0,040242

Результаты. В рамках данной работы были рассмотрены математические модели на основе градиентного бустинга по данным обучающего набора (dataset).

Получены следующие лучшие параметры математической модели:

1. Для глубины шва: $n_estimators = 100$, $loss = MSE$, $max_depth = 3$, $max_features = 2$, $min_samples_leaf = 1$, $min_samples_split = 7$.

2. Для ширины шва: $n_estimators = 100$, $loss = MAE$, $max_depth = 3$, $max_features = 3$, $min_samples_leaf = 1$, $min_samples_split = 4$.

Оценки готовых моделей представлены в табл. 6.

Таблица 6

Оценки модели при тестировании cv_score

Модель	R2	MAE
Depth	0,896255	0,044262
Width	0,960603	0,040242

Как видно из оценок математической модели на основе градиентного бустинга, предложенная модель способна решать задачу поддержки принятия технологических решений на основе градиентного бустинга с достаточно низким значением средней абсолютной ошибки и высоким значением коэффициента детерминации.

Заключение. В результате проведения исследовательской работы выполнен анализ применимости метода Gradient Boosting Regressor как основы для создания математической модели оптимизации и прогнозирования технологического процесса электронно-лучевой сварки. Исходя из полученных оценок модели, можно судить о допустимости использования предложенного подхода для поддержки принятия технологических решений при управлении технологическими процессами, имеющими схожие статистические зависимости.

Полученная модель позволяет с достаточно высокой точностью осуществлять поддержку принятия технологических решений в процессе электронно-лучевой сварки разнородных материалов. Использование методики позволит повысить качество управления технологическим процессом электронно-лучевой сварки. Результаты данного исследования планируется использовать в дальнейших исследованиях, предназначенных для поддержки принятия решений применительно к другим технологическим процессам, имеющим сходные статистические зависимости.

Благодарности. Исследование выполнено при финансовой поддержке РФФИ, Правительства Красноярского края и Краевого фонда науки в рамках научного проекта № 19-48-240007 «Математическое и алгоритмическое обеспечение процесса электронно-лучевой сварки тонкостенных конструкций аэрокосмического назначения».

Acknowledgment. The reported study was funded by RFBR, Government of the Krasnoyarsk Territory and the Regional Science Foundation, project number 19-48-240007 “Mathematical and algorithmic support of the electron-beam welding of thin-walled aerospace structures”.

Библиографические ссылки

1. Вопросы управления формированием сварного шва при электронно-лучевой сварке / В. Я. Браверман, В. С. Белозерцев, В. П. Литвинов и др. // Сибирский журнал науки и технологий. 2008. № 2 (19). С. 148–152.
2. Weglowski M. S., Blacha S., Phillips A. Electron beam welding – Techniques and trends – Review // Vacuum. 2016. Vol. 130. P. 72–92.
3. Автоматизированное оборудование и технология для пайки волноводных трактов космических аппаратов / С. К. Злобин, М. М. Михнев, В. Д. Лаптенко и др. // Сибирский журнал науки и технологий. 2014. №. 4 (56). С. 219–229.
4. Modeling of thermal processes in waveguide tracts induction soldering / A. V. Murygin, V. S. Tynchenko, V. D. Laptenok et al. // IOP Conference Series: Materials Science and Engineering, 2017. Vol. 173, No. 1. P. 012026.
5. Aydin K., Kaya Y., Kahraman N. Experimental study of diffusion welding/bonding of titanium to copper // Materials & Design. 2012. Vol. 37. P. 356–368.
6. Mathematical models of beam input and output in the process of electron beam welding of thin-walled structures / S. O. Kurashkin, V. S. Tynchenko, Y. N. Seregin et al. // Journal of Physics: Conference Series. 2020. Vol. 1515. P. 052048.
7. The concept of an electron beam I/O control system to optimize the weld formation in the process of electron beam welding / V. S. Tynchenko, A. V. Milov, V. V. Bukhtoyarov et al. // Journal of Physics: Conference Series. 2019. Vol. 1399, No. 4. P. 044092.
8. Duffy N., Helmbold D. Boosting methods for regression // Machine Learning. 2002. Vol. 47, No. 2–3. P. 153–200.
9. Goodfellow I., Bengio Y., Courville A. Deep learning. Cambridge, MA: MIT press, 2016. 318 p.
10. Tracking-by-segmentation with online gradient boosting decision tree / J. Son, I. Jung, K. Park et al. // Proceedings of the IEEE International Conference on Computer Vision. 2015. P. 3056–3064.

11. Cost efficient gradient boosting / S. Peter, F. Diego, F. A. Hamprecht et al. // *Advances in Neural Information Processing Systems*. 2017. P. 1551–1561.
12. Салахутдинова К. И., Лебедев И. С., Кривцова И. Е. Алгоритм градиентного бустинга деревьев решений в задаче идентификации программного обеспечения // *Научно-технический вестник информационных технологий, механики и оптики*. 2018. Т. 18, №. 6. С. 1016–1022.
13. Дьяконов И. Д., Новикова С. В. Решение задачи прогнозирования при помощи градиентного бустинга над решающими деревьями // *Научный форум: технические и физико-математические науки*. 2018. С. 9–12.
14. Scikit-learn: Machine learning in Python / F. Pedregosa, G. Varoquaux, A. Gramfort et al. // *The Journal of Machine Learning research*, 2011. Vol. 12. P. 2825–2830.
15. VanRossum G., Drake F. L. The python language reference. Amsterdam, Netherlands : Python software foundation. 2010. 162 p.
16. Schapire R. E., Freund Y. Boosting: Foundations and algorithms // *Kybernetes*. 2013. Vol. 42, No. 1. P. 164–166.

References

1. Braverman V. Ya., Belozertsev V. S., Litvinov V. P., Rozanov O. V. [Issues of managing weld formation in electron beam welding]. *Sibirskiy zhurnal nauki i tekhnologii*. 2008,. Vol. 2 (19), P. 148–152 (In Russ.).
2. Weglowski M. S., Blacha S., Phillips A. Electron beam welding – Techniques and trends – Review. *Vacuum*. 2016, Vol. 130, P. 72–92.
3. Zlobin S. K., Mikhnev M. M., Laptinok V. D., Seregin Yu. N., Bocharov A. N., Tynchenko V. S., Dolgoplov B. B. [Automated equipment and technology for soldering waveguide paths of spacecraft]. *Sibirskiy zhurnal nauki i tekhnologii*. 2014, No. 4 (56), P. 219–229 (In Russ.).
4. Murygin A. V., Tynchenko V. S., Laptinok V. D., Emilova O. A., Seregin Y. N. Modeling of thermal processes in waveguide tracts induction soldering. *IOP Conference Series: Materials Science and Engineering*. 2017, Vol. 173, No. 1, P. 012026.
5. Aydin K., Kaya Y., Kahraman N. Experimental study of diffusion welding/bonding of titanium to copper. *Materials & Design*. 2012, Vol. 37, P. 356–368.
6. Kurashkin S. O., Tynchenko V. S., Seregin Y. N., Petrenko V. E., Milov A. V., Murygin A. V. Mathematical models of beam input and output in the process of electron beam welding of thin-walled structures. *Journal of Physics: Conference Series*. 2020, Vol. 1515, P. 052048.
7. Tynchenko V. S., Milov A. V., Bukhtoyarov V. V., Kukartsev V. V., Tynchenko V. V., Bashmur K. A. The concept of an electron beam I/O control system to optimize the weld formation in the process of electron beam welding. *Journal of Physics: Conference Series*. 2019, Vol. 1399, No. 4, P. 044092.
8. Duffy N., Helmbold D. Boosting methods for regression. *Machine Learning*. 2002, Vol. 47, No. 2–3, P. 153–200.
9. Goodfellow I., Bengio Y., Courville A. Deep learning. Cambridge, MA, MIT press, 2016, 318 p.
10. Son J., Jung I., Park K., Han B. Tracking-by-segmentation with online gradient boosting decision tree. *Proceedings of the IEEE International Conference on Computer Vision*. 2015, P. 3056–3064.
11. Peter S., Diego F., Hamprecht F. A., Nadler B. Cost efficient gradient boosting. *Advances in Neural Information Processing Systems*. 2017, P. 1551–1561.
12. Salakhutdinova K. I., Lebedev I. S., Krivtsova I. Ye. [Gradient boosting algorithm for decision trees in the software identification problem]. *Nauchno-tekhnicheskiiy vestnik informatsionnykh tekhnologiy, mekhaniki i optiki*. 2018, Vol. 18, No. 6, P. 1016–1022 (In Russ.).

13. Dyakonov I. D., Novikova S. V. [Solution of the forecasting problem with the help of gradient boosting over decision trees]. *Nauchnyy forum: Tekhnicheskiye i fiziko-matematicheskiye nauki*. 2018, P. 9–12.
14. Pedregosa F., Varoquaux G., Gramfort A., Michel V., Thirion B., Grisel O., Vanderplas J. Scikit-learn: Machine learning in Python. *The Journal of Machine Learning research*. 2011, Vol. 12, P. 2825–2830.
15. VanRossum G., Drake F. L. The python language reference. Amsterdam, Netherlands, Python software foundation. 2010, 162 p.
16. Schapire R. E., Freund Y. Boosting: Foundations and algorithms. *Kybernetes*. 2013, Vol. 42, No. 1, P. 164–166.

© Тынченко В. С., Головенко И. А., Петренко В. Е., Милов А. В., Мурыгин А. В., 2020

Тынченко Вадим Сергеевич – кандидат технических наук, доцент, доцент кафедры информационно-управляющих систем; Сибирский государственный университет науки и технологий имени академика М. Ф. Решетнева. E-mail: vadimond@mail.ru.

Головенко Игорь Александрович – магистрант кафедры информационно-управляющих систем; Сибирский государственный университет науки и технологий имени академика М. Ф. Решетнева. E-mail: golovonokia@mail.ru.

Петренко Вячеслав Евгеньевич – аспирант кафедры информационно-управляющих систем; Сибирский государственный университет науки и технологий имени академика М. Ф. Решетнева. E-mail: dpblra@inbox.ru.

Милов Антон Владимирович – аспирант кафедры информационно-управляющих систем; Сибирский государственный университет науки и технологий имени академика М. Ф. Решетнева. E-mail: helehad@gmail.com.

Мурыгин Александр Владимирович – доктор технических наук, профессор, заведующий кафедрой информационно-управляющих систем; Сибирский государственный университет науки и технологий имени академика М. Ф. Решетнева. E-mail: avm514@mail.ru.

Tynchenko Vadim Sergeevich – Cand. Sc., docent, associate professor of Information-control Systems department; Reshetnev Siberian State University of Science and Technology. E-mail: vadimond@mail.ru.

Golovenok Igor Aleksandrovich – master student of Information-control Systems department; Reshetnev Siberian State University of Science and Technology. E-mail: golovonokia@mail.ru.

Petrenko Vyacheslav Evgenievich – post-graduate student of Information-control Systems department; Reshetnev Siberian State University of Science and Technology. E-mail: dpblra@inbox.ru.

Milov Anton Vladimirovich – post-graduate student of Information-control Systems department; Reshetnev Siberian State University of Science and Technology. E-mail: helehad@gmail.com.

Murygin Aleksandr Vladimirovich – Dr. Sc., professor, head of Information-control Systems department; Reshetnev Siberian State University of Science and Technology. E-mail: avm514@mail.ru.